

# CV-总结

- Gestalt laws (格式塔法则)

- 邻近法则：人倾向于将视觉中相邻的物体视为一个整体；
- 相似法则：人倾向于将视觉中相似的物体视为一个整体；
- 共同命运法则：人倾向于将视觉中做同样运动的物体视为一个整体；
- 对称法则：人倾向于将物体视为对称的；
- 连续法则：人倾向于将物体视为连续的；
- 闭合法则：人倾向于将物体视为完整的；（即补全残缺的基本图形）

- 计算机视觉处理层次

- Low-level vision (低层视觉)

对输入的原始图像进行处理。进行图像滤波、增强、边缘检测等提取角点、线条、边界、运动等。例如：角点检测、Canny边缘检测。

- Middle-level vision (中层视觉)

恢复场景的深度、表面法线方向、轮廓等有关场景的2.5维信息。实现途径有立体视觉、测距成像等。例如：图像分割、图像拟合、目标跟踪、Hough检测等。

- High-level vision (高层视觉)

在原始输入图像与其基本特征，2.5维图的基础上，恢复物体的完整三维图，建立物体的三维描述，识别物体并确定物体的位置和方向等。例如人脸识别、目标识别、目标检测等。

- 二值图像


- 几何特性

有**面积**、**中心**、**方向**（若物体是方形，长轴方向为物体方向。圆形没有方向。求解方向即取一条直线，使得物体上的点到直线的距离之和最小）。

还有**伸长率**（最长方向与最短方向轴之比）、**密集度**（ $A/p^2$ ,  $p$ 为周长， $A$ 为面积）、**形态比**（区域的最小外接矩形的长和宽之比）。

还有**欧拉数**（连通分量数-洞数，在拉伸形变时保持不变）。

- 投影计算



- 连通区域

四连通邻点：只有上下左右相邻。八连通邻点：八个方向相邻。

- 连通分量标记算法（序贯）

扫描两次。第一次按序扫描，找到一个前景点，按下列规则进行：

1. 如果上面和左面点没有标记，则分配一个新标记，并将其输入等价表。
2. 如果上面和左面点有且仅有一种标记，则复制这个标记。
3. 若上面和左面点标记不同，则复制上面的点的标记（因为它先标记的，所以标记序号较小），并将这两个序号在等价表中标记为等价。

第二次扫描将等价表中等价的标记在图中统一标记为最小的那个标记。

- 区域边界跟踪算法

1. 扫描一遍，找到一个边缘点。

2. 以这个点为中心，周围八个点从左邻点开始按逆时针方向依次判断，找到第一个不属于前景点的点，然后按这个点重复步骤2，直到遇到之前探测过的点。

## • 边缘

### ◦ 模板卷积

计算方法就是做卷积。

### ◦ 四种最主要的不连续

- 表面法线不连续
- 表面颜色不连续
- 深度不连续
- 光照不连续

### ◦ 边缘检测的基本思想

一阶导数的局部极大值或二阶导数的零点。

### ◦ 基于一阶的边缘检测

**梯度:**  $G(x, y) = [G_x, G_y] = [\frac{df}{dx}, \frac{df}{dy}]$ . 图像中一般用差分近似偏导数:

$$G_x = f[x+1, y] - f[x, y], G_y = f[x, y] - f[x, y+1].$$

**梯度幅值:**  $|G(x, y)| = \sqrt{G_x^2 + G_y^2}$ .

**梯度方向:**  $a(x, y) = \arctan(G_y/G_x)$ .

#### ■ Roberts交叉算子

$$G_x = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, G_y = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

#### ■ Sobel算子

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

#### ■ Prewitt算子

### ◦ 基于二阶的边缘检测

#### ■ 拉普拉斯算子

#### ■ LoG算子

使用G（高斯滤波）：平滑去噪和边缘检测是一对矛盾，应用高斯函数一阶导数在二者之间获得最佳平衡。

### ◦ Canny边缘检测

1. 用高斯滤波器平滑图像；
2. 用一阶偏导有限差分计算梯度幅值和方向；
3. 对梯度幅值进行非极大抑制（NMS）；
4. 用双阈值算法检测和连接边缘。


**非极大抑制:** 去掉幅值局部变化非极大的点。先将梯度角离散为圆周的四个扇区之一，然后将方向角离散化，这样那些局部的点就被离散到相同的方向角了。然后判断每一个点，若它不比沿梯度线方向上的两个相邻点幅值大，则将它赋值0。

**双阈值:** 高于高阈值的点判断为边缘。介于高阈值和低阈值的点，若其和边缘8邻点相邻，则判断为边缘。若只取一个阈值，太低造成假边缘，太高使部分轮廓丢失。

## • 曲线（Hough变换）

用来检测图像中的基本图形。运用了 **投票** 的思想。对图像中每一点对应的参数组合进行投票，票多的参数为所检测图形的参数。

比如检测直线，使用极坐标方程，参数有  $\rho, \theta$ 。



**Hough直线检测步骤：**  $(\rho = x\cos\theta + y\sin\theta)$

1. 适当地量化参数空间；
2. 将整个参数空间视为一个累加器，初始化为0；
3. 对图像空间每一点所满足的参数方程对应的累加器元素加1；
4. 累加器阵列最大值即为对应的模型的参数。

**Hough圆弧检测步骤：**  $(b = a\tan\theta - x\tan\theta + y)$

1. 量化关于a, b的参数空间；
2. 初始化累加器为0；
3. 计算图像空间中边缘点的梯度幅度G和角度 $\theta$ ；
4. 将边缘点在上述公式中对应的所有累加器元素加1；
5. 累加器阵列最大值即为对应的圆弧的圆心；
6. 得到圆心坐标后，很容易反求半径。（在记录累加器时顺便记录其对应的每个点）

## • 局部特征

### ◦ Harris角点检测

在一个小区域中小幅度振动，如果各个方向变化剧烈，说明该区域是角点，特征点。

**公式推导：**

$$I(x+u, y+v) \approx I(x, y) + uI_x(x, y) + vI_y(x, y)$$

$$\begin{aligned} E(u, v) &= \sum_{x, y} w(x, y) [I(x+u, y+v) - I(x, y)]^2 \\ &= \sum_{x, y} w(x, y) [I(x, y) + uI_x(x, y) + vI_y(x, y) - I(x, y)]^2 \\ &= \sum_{x, y} w(x, y) [uI_x(x, y) + vI_y(x, y)]^2 \\ &= [u, v] \left( \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right) \begin{bmatrix} u \\ v \end{bmatrix} \end{aligned}$$

令M矩阵等于中间的那部分元素。则可以通过计算它的特征值来判断该点是否是角点。上式中 $I_x, I_y$ 分别是该点的x、y方向的一阶导数。

$$R = \det M - k (\text{trace } M)^2$$

$$\begin{aligned} \det M &= \lambda_1 \lambda_2 \\ \text{trace } M &= \lambda_1 + \lambda_2 \end{aligned}$$

k一般取0.04-0.06。若|R|很小，则说明是平坦区，若 $R < 0$ ，则说明是边缘，若 $R > 0$ ，说明是角点。

其中 $\lambda_{max}$ 表示变化最快的方向， $\lambda_{min}$ 表示变化最慢的方向。

### ◦ SIFT描述子

给定两张同一场景的图片，它们之间有较大差异。在每幅图像上找到相同的特征点。

#### ■ Full vision基本计算步骤

##### 1. 特征点提取。

对图像做降采样（对每张图片应用不同 $\sigma$ 的高斯核函数卷积），得到一组图像。将每组图像做差分得到图像金字塔，在图像金字塔中对比每个点，若它是它的8邻点和上下层的点中的极大/极小值，则该点为特征点。

##### 2. 特征点过滤。

##### 3. 16\*16窗口放在特征点处

##### 4. 将16\*16窗口分为4\*4的窗口计算边缘取向（梯度-90°）。

5. 舍去能量小的点。
  6. 将每个小窗口的所有方向离散成8个方向，一共128个方向特征，然后比对两张图中的这些方向特征。
- 使用梯度信息可以表示边缘信息，特征更稳定，在光照变化时具有稳定性。
  - 各种不变性：
    1. 平移不变、旋转不变：当平移旋转时，特征点的周围点也随之一起移动，所以特征不会变。
    2. 灰度仿射不变：使用梯度进行对比，同时进行了归一化等操作。
    3. 尺度不变：使用金字塔模型，对每一种尺度都能进行检测，所以具有尺度不变性。（通过前一步计算LoG得到的尺度来确定特征，所以在不同尺度都能得到类似的特征）

## • 图像拼接

### ◦ RANSAC (Random sample consensus)

可以用来计算匹配模型。

#### ■ 核心思想

我们希望避免异常值的影响，只得到正常值。当我们用异常值作为参数时，模型大部分点都不会匹配。我们选择匹配数最多的模型，该模型参数很大概率没有异常值。

#### ■ 基本步骤 (loop)

1. 随机选取一组种子点作为内群
2. 计算拟合内群的模型
3. 把其他刚才没选的点带入到建立的模型中，计算是否是内群
4. 记下内群数量
5. 重复以上步骤
6. 比较内群数量最多的模型，此模型参数即为解

- 当正常点比例为 $w$ ，总共有 $n$ 个点时，单次采样的正确率为 $w^n$ 。k次采样失败的概率为 $(1 - w^n)^k$ 。

### ◦ 图像拼接

1. 检测关键点
2. 建立SIFT描述子
3. 根据SIFT进行特征匹配
4. 根据匹配的特征点对计算变换矩阵（6变量）
  1. 变换矩阵T。一组点对提供x, y两个方程，至少需要3个点对才能求出6变量的变换矩阵。
  2. 使用RANSAC提高求解准确度。
5. 图像混合：高斯金字塔求出拉普拉斯金字塔，然后上采样恢复图像。

## • 主成分分析

PCA方法的基本思想是缩小化特征维度。在某些方向上非常分散的数据用PCA比较有效。

### ◦ 算法推导

d维空间原始数据： $x = (x_1, x_2, \dots, x_d)$ 。

投影方向： $a_1 = (a_1^1, a_1^2, \dots, a_1^d)^T, a_1^T a_1 = 1$ 。

投影值： $z_1 = a_1^T x = \sum_{i=1}^d a_1^i x_i$ 。

我们要求解在某投影方向下 $z_1$ 的最大化分散程度，即 $\arg \max_{a_1} \text{var}(z_1)$ 。

$$\begin{aligned}
\text{var}(z_1) &= E(z_1^2) - [E(z_1)]^2 = E\left[\left(\sum_{i=1}^d a_1^i x_i\right)^2\right] - \left(E\left(\sum_{i=1}^d a_1^i x_i\right)\right)^2 \\
&= \sum_{i,j=1}^d a_1^i a_1^j E(x_i x_j) - \sum_{i,j=1}^d a_1^i a_1^j E(x_i) E(x_j) \\
&= \sum_{i,j=1}^d a_1^i a_1^j [E(x_i x_j) - E(x_i) E(x_j)] \\
&= \sum_{i,j=1}^d a_1^i a_1^j S_{ij} \quad \text{令 } S_{ij} = E(x_i x_j) - E(x_i) E(x_j) \\
&= \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1 \quad \text{S ?} \quad \text{cov}(x_i, x_j) = E(x_i x_j) - E(x_i) E(x_j)
\end{aligned}$$

最大化  $\text{var}(z_1) = \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$  subject to  $\mathbf{a}_1^T \mathbf{a}_1 = 1$

典型的等式约束下的最优化问题，可以用Lagrange乘子法  
 设 $\lambda$ 为Lagrange乘子，则转为最大化

$$\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1 - \lambda (\mathbf{a}_1^T \mathbf{a}_1 - 1)$$

求微分，得必要条件：

$$\mathbf{S} \mathbf{a}_1 - \lambda \mathbf{a}_1 = 0 \implies \mathbf{S} \mathbf{a}_1 = \lambda \mathbf{a}_1$$

最大化  $\text{var}(z_1) = \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$  subject to  $\mathbf{a}_1^T \mathbf{a}_1 = 1$

$$\implies \text{var}(z_1) = \mathbf{a}_1^T \lambda \mathbf{a}_1 = \lambda \mathbf{a}_1^T \mathbf{a}_1 = \lambda$$

S为协方差矩阵。

#### • 特征脸 (Eigenface)

Eigenface即构成脸的特征脸，也就是上述计算的“基”中的特征向量。

○ 人脸 $f$ 识别基本步骤 ( $y_f = A^T f$ )

1. 获得人脸图像训练集，对所有人脸做归一化处理。
2. 通过PCA计算获得一组特征向量A。通常100足够。
3. 将每幅人脸图像都投影到该组特征向量空间中，得到在该空间下的“坐标”。
4. 对输入的一幅待测图像，归一化后将其映射到该特征空间中，也得到一个“坐标”，将它与3中得到的人脸库中的“坐标”对比，判断相似性。

○ 人脸 $f$ 重构基本步骤 ( $\hat{f} = A y_f$ )

1. 将其映射到特征空间中，然后选取前n个成分重新组合。

#### • 图像频域与图像分解

○ 图像的傅里叶变换

傅里叶变换存储每个频率的幅度和相位。

**高频区**：图像亮度灰度变化剧烈的地方，对应边缘。

**低频区**：图像亮度灰度变化不大的地方，对应大片色块。

○ 图像分解

根据傅里叶变换思想，图片可以分解为不同频率的子图。

拉普拉斯金字塔由高斯金字塔作差得到。高斯金字塔由高斯滤波器处理图像得到。

高斯金字塔每层是低通滤波，拉普拉斯金字塔每层是带通滤波。因为拉普拉斯金字塔由高斯金字塔的每层与其高一层图像放大相减得到，此过程相当于带通滤波。

## • 物体识别

### ◦ 基本任务

1. 图像分类
2. 检测和定位物体
3. 估计语义和几何属性
4. 对人类活动和事件进行分类

### ◦ 挑战因素

1. 视角变化
2. 光线变化
3. 尺度变化
4. 物体形变
5. 物体遮挡
6. 背景凌乱
7. 类内变换

### ◦ 词袋 (BoW)

宽松的定义：物体的一些独立的特征。

严格的定义：独立特征与其直方图表示。

**基本步骤：**

1. 特征提取与表示
2. 通过聚类从训练样本中对特征进行分组形成“字典”
3. 用“字典”的直方图表示图像
4. 使用词袋分类未知图像

### ◦ 卷积

卷积层可以从图像中提取特征，而物体识别需要用到特征，所以我们可以使用卷积来优化物体识别问题。

$\hat{y} = SM(Wx)$ ,  $x$ 即上一层的输入， $W$ 为 $x$ 和 $y$ 层之间的连接权重。 $SM$ 为sigmoid激活函数。 $y$ 即为根据特征预测的各识别种类的值。

$c_{pred} = \arg \max(\hat{y})$ , 取 $y$ 的最大值作为预测值。

## • 深度学习

端到端学习：直接通过原始输入进行预测。

神经网络的学习，数学本质上是求解神经网络的连接权重。

Step 3: Learn the model

$$w^* = \arg \min_w \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, w), y_i) + R(w)$$

Diagram labels and arrows:

- $w^*$ : Learned weights
- $\arg \min_w$ : Minimize average loss over training set
- $\ell(f(x_i, w), y_i)$ : Loss function: Measures "badness" of prediction
- $R(w)$ : Regularizer: Penalizes complex models
- $f(x_i, w)$ : Predicted output

**梯度下降：**


用来找到使得loss\_function最小的方向。模拟人下山，则权重更新可以视为：

$$w = w - \alpha \nabla g(w)$$

## • BP反向传播

BP算法的作用是计算损失函数相对于神经网络参数的梯度，而梯度下降法是一种优化算法，用来寻找最小化损失函数的参数。梯度下降法及其他优化算法等都依赖BP来得到梯度。

**计算图：**



正向计算即正常按运算法则计算。

反向传播：当结果的误差为 $n$ ，则根据链式法则，

$$z = n * q = 3, q = n * z = -4, x = q * 1 = -4, y = q * 1 = -4.$$

即反传的值为该点的值\*该算子的正向导数值。

另：sigmoid函数的反向传递值为 $(1 - \sigma(x))\sigma(x)$ ， $\sigma(x)$ 为使用sigmoid函数正向计算的最终值。这也是很多网络选择sigmoid函数作为激活函数的原因，反向传播很容易计算。

## • CNN

卷积层利用卷积核进行卷积来进行层与层之间的传递，提取特征。

卷积层依靠 1.将 $n*n$ 数量的数据缩减为1个。2.在整个输入上使用同一个卷积核。来减小计算量。

**卷积操作**：将卷积核与输入对齐， $n*n$ 的空间里对应元素相乘再相加。如果有多通道，相加即可。然后用 $m$ 个卷积核获得 $m$ 大小的特征。

## • 图像分割

图像分割是将像素分组为有意义或感知上相似的区域（格式塔原则），所以可以使用聚类算法。

### ◦ K-means聚类

由于K的选取需要人为，同时鲁棒性较差，所以一般不选用这个方法。

### ◦ Mean Shift聚类

使用 $L*u*v$ 色彩空间，而不是用 $rgb$ 空间。（因为在感官上颜色相近的区域可能并不是一个整体）。

1. 在空间内初始化几个聚类中心，以及一定大小的半径。
2. 计算每个中心+半径范围内的质心（即按照点的密集度来确定中心），然后将聚类中心移动到质心处，重复该步骤直到中心不再移动。
3. 这个偏移量的计算方式为 $f(x) = \frac{1}{n} \sum_{i=1}^n K(x - x_i)$ ， $K$ 为核函数，代表不同质心的计算方式。

这个方法虽然中心数量也需要人为确定，但是鲁棒性强。

## • 光流

解决的问题：评估从 $H$ 到 $I$ 的像素运动，给出图像 $H$ 中的一个像素，找到图像 $I$ 中相同颜色的相近像素，即像素对应问题。

### ◦ 三个基本假设

1. 亮度恒定性

$$I(x + u, y + v, t + 1) = I(x, y, t).$$

2. 空间相干性

3. 细微运动

### ◦ 点约束公式

$$O = I(x + u, y + v) - H(x, y) = [I(x, y) - H(x, y)] + uI_x + vI_y = I_t + uI_x + vI_y = I_t + \nabla I[u, v]$$

一般选择纹理复杂区域，因为梯度比较大且方向不同，求出来的特征值比较大。


## • 相机模型

相机原理：小孔成像。这个孔即光圈。

光圈越大，一个点经过这个点在胶卷上映射的范围越大，图片越模糊。

光圈越小，容易发生衍射，同样会使图片模糊。

可以添加一个透镜来使得透过的光集中且多，也不会发生衍射。




**景深**：光圈越小，景深越大。但是小光圈透过的光少，需要增加曝光时间。

**视场**：焦距越小，视场越大。 $\theta = \tan^{-1}(\frac{d}{2f})$ 。

焦距大，整个场景被缩短，远处的东西被拉近放大，但是虚化了，焦距内的物体也能看到。

焦距小，整个场景被拉长，远处的东西很小，但是很清楚，焦距内的物体在视野外。

#### 理想针孔相机模型



将图像转换到PP图像平面。

转换基本方程： $(x, y, z) \rightarrow (-d\frac{x}{z}, -d\frac{y}{z}, -d) \rightarrow (-d\frac{x}{z}, -d\frac{y}{z})$ 。

- **齐次坐标**：可以看到，基本方程中的转换除以 $z$ ，所以不是线性转换。我们添加一个参数1。则齐次坐标系下的透视投影公式为：

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -1/d & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x \\ y \\ -z/d \\ 1 \end{bmatrix} \Rightarrow (-d\frac{x}{z}, -d\frac{y}{z})$$

齐次坐标系的好处是：可以合并矩阵运算的乘法和加法。（区分向量和点、易于仿射变换）

投影平面上任意点都可以表示为一个三元组 $(x, y, z)$ ，当 $z \neq 0$ ，该点表示欧式平面点 $(\frac{x}{z}, \frac{y}{z})$ 。当 $z = 0$ ，该点表示欧式平面无穷远点。

对于刚体变换 $x' = Rx + t$ ，齐次变换矩阵为： $\begin{bmatrix} R & t \\ 0 & 0 & 0 & 1 \end{bmatrix}$ 。

#### 相机参数：

**内参**（不随相机位置变化的参数，相对于成像平面）：

1.  $f_u = fk_u$ ：u向焦距
2.  $f_v = fk_v$ ：v向焦距
3.  $u_0$ ：主点坐标u
4.  $v_0$ ：主点坐标v

内参矩阵：

$$\begin{bmatrix} -f_u & 0 & u_0 & 0 \\ 0 & -f_v & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

**外参**（从世界坐标系转换到相机坐标系）：

6个： $(\theta, \varphi, \psi, t_x, t_y, t_z)$ 。前三个为z,y,x轴的旋转参数，后三个为x,y,z轴的位移参数。

外参矩阵：



$$\begin{bmatrix} R_{3 \times 3} & t_{3 \times 1} \\ 0 & 0 & 0 & 1 \end{bmatrix}.$$

$$R_x(\psi) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \psi & \sin \psi \\ 0 & -\sin \psi & \cos \psi \end{bmatrix} \quad R_y(\varphi) = \begin{bmatrix} \cos \varphi & 0 & -\sin \varphi \\ 0 & 1 & 0 \\ \sin \varphi & 0 & \cos \varphi \end{bmatrix} \quad R_z(\theta) = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

R是以上三个3×3矩阵相乘的结果。

#### 畸变

我们为了使收集的光增多且集中所以使用了透镜，但这也引入了畸变。

##### ■ 径向畸变

产生原因：透镜形状不完美。穿过透镜边缘的光偏差比较大。

产生类型：桶型畸变，针型畸变。

##### ■ 切向畸变

产生原因：光学元件组装过程的偏心。

##### ■ 畸变参数：( $k_1, k_2, p_1, p_2, k_3$ ): k为径向畸变参数, p为切向畸变参数。

#### 四个坐标系：

物体坐标系——世界坐标系——相机坐标系——像平面坐标系——像素坐标系

|——外参——| |——内参——| 畸变参数纠正

#### • 相机定标

给定：N组对应的黑白场景和图像。

恢复：相机的参数：内参、外参、畸变参数。

解决的思想：找三维空间中已知的几何形状作为校准标准。校准对象通常由两个或三个相互正交的平面组成。

##### ○ 基于Homography的相机定标

优点：灵活性、稳定性、低成本。

只需要拍摄几张不同角度的象棋棋盘的图片即可。

步骤：


1. 获取标定物体网格的角点在坐标系的位置。
2. 找到图片的角点。
3. 根据图像空间坐标系到世界坐标系列出等式。
4. 求解相机参数。

Homography矩阵的自由度为8（因为矩阵为3×3的，选一个点为确定点，剩8个不确定的），求解需要4个点对。

#### • 立体视觉

##### ○ 三角测量原理（相似三角形）

$$\frac{T - (x^l - x^r)}{Z - f} = \frac{T}{Z} \Rightarrow Z = \frac{fT}{x^l - x^r} \quad \text{Triangulation}$$



当两个观测点距离越远、相机焦距越大，对距离的判断越准确，但是可感受深度的视场变小了。


##### ○ 立体视觉四步骤

1. 消除畸变
2. 校正相机
3. 两幅图中找共同特征
4. 进行三角测量

## • 结构光三维成像

结构光成像系统的构成：结构光投影仪+CCD相机+深度信息重建系统。

### ◦ 利用结构光获取三维数据基本原理



### ◦ ICP迭代最近点算法

解决问题：将多个扫描结果拼接在一起形成扫描对象的完整描述。

基本步骤（给定两个三维点集X与Y，将Y精准匹配到X）：

1. 计算Y中每个点在X中的对应最近点；
2. 求使上述对应点的平均距离最小的刚体变换，获得刚体变换参数（平移、旋转参数）；
3. 对Y应用上一步求得的刚体变换（平移与旋转），更新Y；
4. 如果X与Y的对应点对平均距离大于阈值，跳到1，否则停止。

思想有点像K-means